

FireWorldBench

火灾物理世界理解 Benchmark 设计方案

面向 LLM / multimodal agent 的火灾预警、火灾识别与火灾演化解理解

核心定位：本 benchmark 不把火灾场景简化为“图像中是否有火”或“传感器是否超过阈值”。它要评估模型是否能从多模态证据背后恢复一个受火灾动力学约束的世界模型：火源、热释放、热羽流、顶棚射流、烟层、通风、能见度、毒性与干预措施之间如何相互作用。

资料核对日期：2026-06-27。本文档用于研究 benchmark 设计，不应用作实际消防系统决策依据。

1. 总体设计

建议将 FireWorldBench 设计为三大任务：火灾预警、火灾识别、火灾演化。三者分别对应火灾系统的早期弱信号、当前隐状态、未来状态转移。这样既符合火灾工程中的关键需求，也能凸显 LLM/agent 相比普通视觉分类器或时序预测器的能力差异。

任务	核心问题	要测的“物理世界理解”	首选数据源
T1 火灾预警	火灾是否正在形成，是否需要提前报警？	弱信号归因、噪声/通风扰动区分、早期风险判断、缺失信息意识。	Immersed Tunnel CFD; PolyUFire sidewall vent; FDS/FD-Gen 扩展; D-Fire/DetectiumFire 视觉辅助。
T2 火灾识别	当前火灾处于什么状态，主导机制是什么？	火源、火灾阶段、通风机制、烟层与回流状态识别，而非单纯 fire/smoke detection。	Immersed Tunnel; PolyUFire 经验表; FDS validation/exp; D-Fire/DFS/DetectiumFire/Fire360。
T3 火灾演化	未来烟气、温度、能见度、风险如何变化？干预后会怎样？	状态转移、反事实、干预推理、物理一致性与证据链。	FDS + FD-Gen 为主; Immersed Tunnel 排烟配置 pairs; PolyUFire 真实温度测试做外部验证。

设计原则：每个任务都应同时给出最终答案、关键物理机制、证据来源和置信度。只给分类标签的样本可以保留作 baseline，但不应作为 benchmark 的核心。

2. 可用数据源与角色分工

数据源	公开内容	最适合支撑的任务	不足与处理建议
Immersed-Tunnel-Fire-Location-Detection-Data https://github.com/zhang-zhen-project/immersed-tunnel-fire-location-detection-data	超宽沉管隧道 FDS/CFD 数据；6 个火源位置、32 种排烟配置、192 个计算结果；CSV 与读取/建模代码。	T1 预警：早期传感器窗口；T2 识别：火源位置与排烟配置；T3 演化：同火源不同排烟策略的反事实 pair。	规模小，配置离散；文件名含标签，发布 benchmark 时需匿名化；缺少自然语言解释、因果链和完整多模态标注。
PolyUFire Tunnel Fire Database https://github.com/PolyU-Fire/Tunnel_Fire_Database	2020 TUST 论文相关整理表：HRR、flame length、ceiling temperature、critical velocity、back-layering、smoke layer thickness、plug-holing 等；另有 sidewall smoke extraction 的 8 组测试温度时序。	T1 预警：真实温度时序；T2 识别：critical velocity/back-layering 等机制标签；T3 演化：温度演化外部验证。	不是完整原始物理场；多为整理表和温度数据；缺少 soot、CO、visibility、velocity 场，需要与 FDS 数据结合。
NIST FDS / firemodels https://pages.nist.gov/fds-smv/ https://github.com/firemodels/fds	FDS/Smokeview 官方工具、验证案例、输入文件与实验对照。	三大任务的物理 ground truth；尤其适合生成 T3 演化和反事实干预样本。	需要自行建模、运行和后处理；计算成本较高；要进行网格、边界条件和验证说明。
FD-Gen https://github.com/usnistgov/FD-Gen	NIST 火灾数据生成工具，可随机化 FDS 参数并批量生成场景。	扩展 T1/T2/T3 的场景覆盖：HRR、火源位置、通风、开口、障碍物、传感器布置等。	需制定参数空间和安全/合理性过滤规则；输出仍需转换成 QA、trace 和 counterfactual 标注。
DetectiumFire https://arxiv.org/abs/2511.02495	多模态火灾安全数据，包含图像、视频、bbox、caption、risk level 等。	T1/T2 的视觉预警与场景识别；可用于训练/评测视觉 grounding。	偏视觉与风险描述，不含完整物理场和干预反事实。
D-Fire https://github.com/gaia-solutions-on-demand/DFireDataset	21k+ 火/烟图像，YOLO bbox，含 fire、smoke、fire+smoke、none。	T1/T2 的视觉 baseline：火/烟检测、误报干扰。	静态图像，不能单独支撑火灾物理演化理解。
Fire360 https://arxiv.org/abs/2506.02167	228 个 360° 消防训练视频，低能见度/热变形等条件，含 VQA、action captioning、object localization、safety reasoning 等任务。	T2 视觉场景识别与安全推理；可补充 degraded perception 场景。	偏消防员视角和感知记忆，不是隧道/建筑火灾 CFD ground truth。

3. 任务一：火灾预警 Fire Early Warning

目标不是检测“是否已经看到明火”，而是评估 agent 是否能在弱信号阶段判断火灾正在形成，并区分真实火灾、传感器噪声、通风扰动和非火灾烟雾。

3.1 子任务设计

子任务	输入	输出	物理解释点
T1-A 早期火灾判别	短窗口传感器：temperature、soot、CO、风速；可选图像/视频帧；隧道/房间布局。	是否预警、风险等级、预警时间、置信度。	弱信号是否形成火灾一致模式；是否理解烟气/温度/CO 的时序关系。
T1-B 异常归因	同上，并提供可能干扰：风机切换、传感器漂移、热源非火灾扰动。	fire / non-fire / ventilation disturbance / sensor fault 分类，并说明证据。	区分生成机制，而非只看数值变大。
T1-C 信息需求选择	给定不完整观测和若干可查询传感器/图像/曲线。	选择下一步最应查看的信息，并说明为什么。	agent 是否知道哪些变量最能区分假设，如通风方向、上游 soot、顶棚温度。

3.2 示例样本

给定：S16 的 soot 在 12 秒开始上升，T12 在 18 秒后升高，T08 基本不变；纵向风向为上游到下游。问题：这更像火灾早期、通风扰动还是传感器故障？请给出预警等级、证据传感器和还需要查看的信息。

3.3 数据集匹配

首选 Immersed Tunnel CFD：可截取 3s/6s/10s/20s 早期窗口，生成“是否应预警、火源区间、受影响区域”的标签。PolyUFire sidewall vent 可作为真实温度时序补充，但变量较少。D-Fire/DetectiumFire/Fire360 可提供视觉预警和火烟误报场景。若要高质量 non-fire 与弱火源样本，应使用 FDS/FD-Gen 生成低 HRR、通风扰动、传感器噪声和无火热源场景。

3.4 推荐指标

包括 AUROC、AUPRC、提前量 lead time、false alarm rate、miss rate、risk calibration、evidence alignment，以及物理解释违规率。对于 LLM/agent，需额外评分：是否正确指出主导机制、是否识别信息不足、是否选择有效补充观测。

4. 任务二：火灾识别 Fire State Recognition

火灾识别不应只做 fire/smoke object detection，而应识别“当前火灾状态”：火源位置或区域、火灾阶段、火势强度、主导输运机制、烟层/回流状态、通风影响和风险区域。

4.1 子任务设计

子任务	输入	输出	物理解释点
T2-A 火灾状态识别	图像/视频、传感器、布局、通风状态。	火灾阶段、火源区域、HRR 档位、风险区域。	从可观测现象推断不可直接观测的隐状态。
T2-B 主导机制识别	同一场景的观测证据和候选机制。	buoyant plume / ceiling jet / longitudinal ventilation / sidewall extraction / backlayering 等机制。	区分“看到了烟”与“理解烟为什么这样走”。
T2-C 物理一致性判断	给出一段解释或模型回答。	判断是否物理合理，并指出错误机制。	检验热浮力、烟层、质量/能量守恒、通风方向等约束。

4.2 示例样本

解释待判定：“高温烟气密度较大，因此火灾初期会优先贴地向上游扩散。” 期望回答：不合理。高温烟气通常密度较低，先由浮力上升形成火羽流，撞击顶棚后形成顶棚射流和烟层；上游回流需要结合通风速度与 critical velocity 判断。

4.3 数据集匹配

Immersed Tunnel 适合做火源位置、排烟配置和受影响区域识别。PolyUFire 的 critical velocity、back-layering length、smoke layer thickness、plug-holing 等整理表适合生成机制识别与物理一致性题。D-Fire、DFS、DetectiumFire 和 Fire360 适合视觉火/烟与安全场景识别，但需要补充机制标签。FDS validation/exp 可作为标准物理机制案例库。

4.4 推荐指标

包括 state accuracy、macro-F1、mechanism F1、physical consistency accuracy、explanation violation rate、evidence sensor precision/recall。对生成式回答，建议把输出结构化为 JSON：answer、mechanism、evidence、uncertainty、violations。

5. 任务三：火灾演化 Fire Evolution Reasoning

这是最能体现火灾物理世界理解的任务。模型需要预测未来状态或比较干预后果，而不是只读当前图像或当前曲线。核心是状态转移、反事实和物理约束。

5.1 子任务设计

子任务	输入	输出	物理解点
T3-A 未来趋势预测	当前观测窗口、空间布局、通风状态。	未来 30/60/120 秒温度、soot、CO、能见度、风险区域的方向性变化或区间。	是否理解烟气随通风和浮力演化。
T3-B 反事实干预推理	Case A 与 Case B，仅改变一个变量：风速、风阀、火源位置、HRR、障碍物。	哪个区域风险上升/下降；传感器响应顺序如何变化；是否更可能 backlayering。	区分相关性和因果性，是 benchmark 的核心样本类型。
T3-C 状态转移追踪	多模态证据 + 问题。	initial_state、dominant_mechanism、transition steps、outcome、evidence。	答案对不够，必须中间物理链也对。

5.2 示例样本

Case A：下游排烟阀开启；Case B：下游排烟阀关闭；其他条件相同。问题：哪个 case 更可能导致下游能见度快速下降？上游 backlayering 风险如何变化？请给出因果链和证据变量。

5.3 数据集匹配

FDS + FD-Gen 是首选，因为演化和反事实需要可控变量和完整 ground truth。Immersed Tunnel 数据天然包含同一火源下不同排烟配置，可构造干预 pair。PolyUFire sidewall vent 提供真实温度演化，可用于验证模型是否能迁移到实验数据。Fire360/DetectiumFire 可补充真实视觉演化，但不能替代物理场 ground truth。

5.4 推荐指标

包括 trend direction accuracy、event time error、ranking accuracy、counterfactual consistency、state trace score、causal edge F1、physical violation rate。对于数值输出可用 MAE/RMSE，但更建议先做区间或排序题，避免 LLM 被不必要的精确数值惩罚掩盖物理推理能力。

6. 样本格式与评分协议

建议每个样本包含 scenario、observations、question、answer、physical_trace、scoring_metadata。核心是把可自动评分部分和专家审计部分分开。

字段	说明
scenario	隧道/房间几何、传感器坐标、火源候选位置、通风/排烟配置、障碍物。
observations	传感器时序、图像/视频帧、Smokeview 截图、风险图、已有曲线。
question	预警、识别或演化问题；可为选择、排序、开放式 JSON。
answer	最终答案：分类、排序、趋势、风险区间或干预选择。
physical_trace	标准物理链：初始状态、主导机制、状态转移、结果、关键证据。
scoring_metadata	可自动评估的事件时间、传感器响应顺序、阈值、反事实方向、因果边。

推荐输出模板

```
{
  "answer": "...",
  "risk_level": "...",
  "dominant_mechanism": "...",
  "causal_chain": [...],
  "evidence": [...],
  "uncertainty": "...",
  "missing_information": [...]
}
```

7. 数据划分与防投机设计

设计点	建议
匿名化	文件名、case ID 不得泄漏火源位置或排烟配置。例如原始 100M32.csv 这类名称必须替换为随机 ID。
OOD split	训练/验证/测试按火源位置、通风配置、HRR、几何布局、传感器布局分层；测试中包含未见过的组合。
Counterfactual pair	同一场景只改变一个变量，要求模型预测方向性变化。
Adversarial explanation	加入物理错误解释，让模型检查热浮力、通风方向、烟层、backlayering、质量守恒等。
Tool-use 限制	agent 可调用绘图、检索、简单公式或 FDS 代理工具，但需记录调用次数和是否真正改善答案。
人类/专家上限	抽样邀请消防工程或火灾动力学背景人员标注，用于校准开放式解释评分。

8. 最小可行版本 MVP

第一版不需要一次性覆盖所有火灾场景。建议以“隧道火灾 + 火/烟视觉辅助”为主，先做可发表、可复现的 MVP。

模块	具体实现
数据	Immersed Tunnel CFD 作为主数据；PolyUFire sidewall vent 作为真实温度验证；D-Fire 或 DetectiumFire 作为视觉识别辅助。
任务	T1 早期预警：3/6/10/20 秒窗口；T2 状态识别：火源区域 + 主导机制；T3 演化：排烟配置反事实 pair。
标注	从 FDS CSV 自动派生：响应顺序、峰值时间、阈值超限、风险方向；人工补充机制解释模板。
基线	传统模型：CNN-LSTM/TCN/Transformer；LLM baseline：text-only、sensor-table QA、LLM+plotting、LLM+retrieval、LLM+tool-use。
主要卖点	不是新的 fire detection 数据集，而是首个面向 LLM/agent 的火灾物理世界理解 benchmark：预警、识别、演化三位一体。

9. 参考资料

- Immersed Tunnel Fire Location Detection Data: <https://github.com/zhang-zhen-project/immersed-tunnel-fire-location-detection-data>
- Zhang et al., Intelligent fire location detection approach for extrawide immersed tunnels, Expert Systems with Applications, 2024: <https://doi.org/10.1016/j.eswa.2023.122251>
- PolyUFire Tunnel Fire Database: https://github.com/PolyUFire/Tunnel_Fire_Database
- NIST FDS/Smokeview Manuals: <https://pages.nist.gov/fds-smv/>
- firemodels/fds: <https://github.com/firemodels/fds>
- FD-Gen: Fire Data Generator, NIST: <https://github.com/usnistgov/FD-Gen>
- DetectiumFire: <https://arxiv.org/abs/2511.02495>
- D-Fire Dataset: <https://github.com/gaia-solutions-on-demand/DFireDataset>
- Fire360: <https://arxiv.org/abs/2506.02167>
- PhysBench: <https://arxiv.org/abs/2501.16411>
- CausalPhys: <https://arxiv.org/abs/2606.05966>
- QuantiPhy: <https://arxiv.org/abs/2512.19526>
- World Models in Words: <https://arxiv.org/abs/2605.29585>

附注：现有公开数据并不能直接完成完整 FireWorldBench。真正的 benchmark 贡献在于把公开火灾/隧道/CFD 数据组织成带有反事实、因果链、状态转移和物理一致性评分的任务集合。